

模倣学習に基づく人とロボットの物理的協調における 意図の不確実性を考慮した適応的剛性制御

Adaptive Stiffness Control Considering Intention Uncertainty in Physical Human–Robot Collaboration Based on Imitation Learning

○学 大竹葵 (慶應大) Ferdinand HARTMANN (慶應大)
猪狩高 (慶應大) 村田真悟 (慶應大)

Aoi OTAKE, Keio University, a.otake2415@keio.jp

Ferdinand HARTMANN, Keio University

Ko IGARI, Keio University

Shingo MURATA, Keio University

To enable robots to interact safely and effectively with humans, we propose an adaptive stiffness control framework that accounts for intention uncertainty in physical human–robot interaction. The proposed framework estimates intention uncertainty using a probabilistic generative model that predicts multiple candidate robot action trajectories. The variability among these trajectories is quantified as statistical variance and interpreted as prediction uncertainty reflecting ambiguity in the human partner's intended motion. This uncertainty is dynamically mapped to the robot's joint stiffness, enabling compliant (low-stiffness) behavior during high-uncertainty phases and firm (high-stiffness) assistance when uncertainty is low. Real-world experiments on collaborative carrying tasks demonstrate that the proposed framework enhances both task success rates and interaction safety by adaptively modulating robot joint stiffness according to human intention.

Key Words: pHRI, Adaptive Stiffness Control, Imitation Learning, CVAE, ACT, FACTR

1 はじめに

ロボット制御技術の実用化が進む中、人の作業空間において物理的な接触を伴いながら協調作業を行う協働ロボットの重要性が高まっている。そのためには、人の動作や環境の変化に柔軟に適応し、接触時の安全性とタスクの円滑な遂行を両立する能力が不可欠である。近年、模倣学習の発展により、学習を通じて強力な方策モデルを獲得することが可能となっている。しかし、これらの手法では一般に制御時の剛性が固定されており、接触時の衝撃吸収や柔軟な対応が困難であるという課題がある。

そこで本研究では、視覚と力覚を統合した方策モデルである FACTR (Force-Attending Curriculum Training for Contact-Rich Policy Learning) [1] に対して、ACT (Action Chunking with Transformers) [2] に着想を得て CVAE (Conditional Variational Autoencoder) 構造を導入し、行動予測の不確実性に基づき剛性を適応的に変化させる制御フレームワークを提案する。人とロボットの協調物体運搬タスクを通じて、本手法が安全性と作業効率の両立に寄与することを検証する。

2 提案手法

2.1 CVAE 構造を用いた方策フレームワーク

本研究では、視覚・力覚統合方策モデルである FACTR を基盤とし、CVAE の構造を導入することで、図 1 に示す確率的な行動生成と不確実性の推定を可能にするフレームワークを提案する。本手法は、各時刻 t における RGB 画像 I_t と外部関節トルク τ_t を入力とする。まず、各入力は潜在表現 z_t^V, z_t^F へとエンコードされ、これらを結合したトークン列が Transformer エンコーダ h_θ に入力される。ここで得られた表現 H_t^E から抽出された表現 $H_t^{E,s}$ に基づき、潜在変数 z をサンプリングし、Transformer デコーダ π_θ に入力される。デコーダ π_θ は H_t^E およびクエリ q_{emb} に加え、この z を条件として与えることでデコード特徴量 H_t^D を算出する。最終的に、特徴量 H_t^D を行動空間へ射影することで、未来 k ステップの予測軌道 $\hat{q}_{t:t+k}$ を得る。




Fig.1 Overview of the proposed framework based on CVAE and FACTR.

2.2 学習における最適化と損失関数

モデルの学習においては、以下の損失関数 $\mathcal{L}$ を最小化することで、観測情報から適切な行動を生成する能力を最適化する。

$$\mathcal{L} = \frac{1}{k} \sum_{i=t}^{t+k} |\hat{q}_i - q_i| + \beta D_{\text{KL}}(q_\phi(z|H_t^{E,s}, q_{t:t+k}) \parallel p_\psi(z|H_t^{E,s})) \quad (1)$$

式 (1) の第 1 項は再構成誤差項であり、予測された軌道 $\hat{q}_i$ と正解の軌道 q_i との間の平均絶対誤差として、モデルの予測精度を直接的に担保する。第 2 項は正則化項であり、近似事後分布 q_ϕ と事前分布 p_ψ の間の KL ダイバージェンスを表す。この正則化項の導入により、正解軌道が得られない推論時においても、視覚・力覚の観測情報のみを入力とする事前分布 p_ψ から、タスク達成に適した潜在変数 z をサンプリングし、状況に応じた確率的な軌道生成を行うことが可能となる。

2.3 不確実性に基づく適応的剛性制御

本フレームワークは、確率的な軌道生成の結果生じるばらつきをモデルの不確実性として定量化し、ロボットの剛性 K_t に動的に反映させる。推論時、事前分布 p_ψ からサンプリングした N 個の潜在変数 z に基づき、 N 個の予測軌道チャンクを生成する。




Fig.2 Analysis of the proposed adaptive stiffness control during a representative rightward movement trial: (Top) weighted prediction uncertainty $\sigma_{t,W}^2$; (Middle) adaptive stiffness gains K_t mapped from $\sigma_{t,W}^2$; and (Bottom) sequential images captured from the side-view camera every 50 steps.

この軌道群のばらつきを、各時刻 k におけるサンプル分散 σ_{t+k}^2 として算出する。さらに、将来ステップの重み w_k を線形に大きく設定した加重平均 $\sigma_{t,W}^2$ を最終的な不確実性の指標として定義する。分散 $\sigma_{t,W}^2$ は、指数移動平均による平滑化を経て、正規化された信頼度係数 α_t へと変換される。この係数を用い、あらかじめ設定した高剛性パラメータ K_H と低剛性パラメータ K_L の間を線形補間することで、最終的な剛性 K_t を決定する。この戦略により、人の意図が曖昧で不確実性が高い局面では、ロボットは剛性を下げて物理的な追従性を高め、人の介入を柔軟に受容する。逆に、不確実性が低い局面では、剛性を高めて人の動作をアシストする。これにより、人とロボットの物理的協調における柔軟な順応とタスク遂行能力の両立を達成する。

3 実験

3.1 実験設定

本実験では、7軸多関節ロボット Franka Research 3 と側面視点カメラを用い、人とロボットが対象物を挟み込んで前後左右の4方向へ運搬する協調タスクを行う。ロボットは 500Hz の周波数で制御され、動的なタスク環境における提案手法の有効性を検証する。一連の動作として、まず人とロボットが向かい合った位置から対象物を保持し、垂直方向へと持ち上げる。その後、人は移動させたい方向に対象物を誘導することでロボットへ移動の意図を伝達し、方向が定まった段階で目的の位置までの水平運搬を行う。このように、垂直方向の挙上から水平方向の誘導、そして運搬へと遷移するプロセスを通じて、ロボットが人の意図を汲み取りながら適切に動作を支援できるかを評価する。

3.2 結果

人とロボットの協調物体運搬タスクにおいて、提案手法と2つの比較条件の評価を行った。比較対象は、提案モデルの剛性を中程度に固定したアブレーション手法、既存手法である FACTR を剛性固定で用いたベースラインである。表1に示す通り、提案手法は全方向においてベースラインを上回る成功率を記録し、平均成功率を 0.65 から 0.92 へと大幅に向上させた。特に、垂直方向の持ち上げ動作と力のベクトルが重なり、意図判別が困難な前方向において、ベースラインは剛性維持による力の拮抗からシステム停止を招いたのに対し、提案手法は 0.93 と顕著な改善を示した。図2の時系列データに示される通り、移動の分岐点において分散が増大し、それに連動してロボットが即座に低剛性へと遷移したことが、この改善に寄与したと考えられる。

また、アブレーション手法として剛性を固定した場合の平均成功率は 0.75 に留まった。特定の方向、特に後ろや左方向については固定剛性下でも比較的円滑な動作が確認されたが、前方向では顕著な性能低下が見られた。これはベースラインと同様に剛性

を固定すると人との物理的な拮抗が強まり、操作者の疲労増大やトルク制限超過によるシステム停止が頻発するためである。固定剛性下では、モデルの予測と人の誘導がわずかに乖離した場合でも、その誤差が反力として操作者に伝わり、物理的な拮抗やトルク制限超過を引き起こす。これに対し、予測の不確実性に基づき剛性を動的に調整する提案手法は、操作者の身体的負荷を軽減しつつ、不確定な局面における物理的な順応性を確保する上で有効であることが示された。

Table 1 Task success rates in each direction.

Method	Fwd.	Bwd.	Left	Right	Avg.
Proposed (Ours)	0.93	0.87	0.93	0.93	0.92
Proposed (Fixed)	0.47	0.93	1.00	0.60	0.75
Baseline	0.27	0.87	0.67	0.80	0.65

4 おわりに

本研究は、視覚・力覚情報を統合した方策モデル FACTR に CVAE 構造を導入し、予測の不確実性に基づいてロボットの剛性を適応的に制御するフレームワークを提案した。実機タスクによる評価の結果、移動の分岐点においてモデルが自律的に低剛性へ遷移することで人の誘導を柔軟に受容し、ベースラインと比較して大幅な成功率の向上を達成した。一方で、操作者の誘導タイミングの遅れや特定の環境要因により、一時的な誤推論が生じるケースも確認された。今後は、潜在変数の表現能力をさらに高度化し、より複雑かつ動的なタスク環境においても、時間・空間解像度の高い不確実性推定に基づいた適切な剛性調整を実現することを目指す。

謝辞

本研究は JST さきがけ (JPMJPR22C9) , 科研費 (JP24K03012) , 栢森情報科学振興財団の支援を受けたものです。

参考文献

- [1] Liu, J. J., Li, Y., Shaw, K., Tao, T., Salakhutdinov, R., and Pathak, D., "FACTR: Force-attending curriculum training for contact-rich policy learning," in *Proceedings of the 2025 Robotics: Science and Systems (RSS)*, 2025.
- [2] Zhao, T. Z., Kumar, V., Levine, S., and Finn, C., "Learning fine-grained bimanual manipulation with low-cost hardware," in *Proceedings of the 2023 Robotics: Science and Systems (RSS)*, 2023.